

Recuperación de sensores averiados en un detector PET de cristal monolítico

Informe de resultados y guía de lectura de las figuras

Miguel Escudero

Agosto de 2026

En dos frases. Una red neuronal que explota la geometría hexagonal del detector reconstruye la carga de un sensor averiado a partir de los sesenta restantes, y recupera algo más de la mitad del error de posición que introduce el fallo, conservando además el espectro de energía y mejorando la resolución espacial. El rendimiento no depende del tamaño de la red ni de la sofisticación de la arquitectura —nueve estrategias distintas no lo mueven—, sino del límite de información que físicamente queda en los sensores supervivientes.

1. Qué problema se resuelve y por qué tiene solución

El detector es un cristal centelleador monolítico leído por **61 fotosensores SiPM** dispuestos en una retícula hexagonal. Cuando un fotón gamma interactúa en el cristal, la luz producida se reparte entre varios sensores, y la posición del impacto se reconstruye como un centro de gravedad de las cargas medidas. Si un sensor se avería, su carga desaparece del cálculo, el centro de gravedad se desplaza y la posición reconstruida queda sistemáticamente sesgada. El módulo entero deja de ser utilizable.

La propuesta consiste en **estimar la carga que habría registrado el sensor averiado** a partir de los sesenta que siguen funcionando, de modo que el cálculo de la posición pueda completarse. Que esto sea posible no es evidente a priori, y conviene justificarlo: la luz de centelleo no cae sobre un único fotosensor sino que se reparte sobre una vecindad, de manera que la información de cada sensor está **parcialmente contenida en los que lo rodean**. Esa redundancia es lo que hace viable la reconstrucción. Y es una redundancia *local*: el tratamiento superficial del cristal confina la luz, así que son los vecinos inmediatos los que llevan la información, no el detector entero.

El entrenamiento es **auto-supervisado**. En un módulo realmente averiado la carga verdadera del sensor muerto es inobservable, así que no existen ejemplos etiquetados. Lo que sí hay son 159 módulos sanos: en ellos se apaga artificialmente un sensor, se le pide a la red que lo reconstruya, y su valor real —que sí conocemos— sirve de respuesta correcta.




Figura 1: Geometría del detector y su gradiente natural. A la izquierda, los 61 sensores dibujados en su posición física real; el color indica la fracción de eventos en los que cada sensor registra señal, desde el violeta oscuro (en torno al 12 %) hasta el amarillo (cerca del 47 %). Se aprecia que **los sensores centrales se activan mucho más a menudo que los de las esquinas**. A la derecha, ese mismo dato representado frente a la distancia al centro del detector: cada punto rojo es un sensor, y la caída es prácticamente monótona. La causa es física: las caras laterales del cristal llevan un adhesivo absorbente que suprime las reflexiones, de modo que en el borde se recoge menos luz. Esta figura conviene tenerla presente porque explica por qué los sensores periféricos son sistemáticamente más difíciles de reconstruir.

2. El resultado, visto de un vistazo

Antes de entrar en métricas conviene mirar el efecto sobre la imagen que se usa a diario en el laboratorio: el *flood map*, el histograma bidimensional de las posiciones reconstruidas. En un detector sano dibuja una retícula regular de puntos, uno por cada sensor.




Figura 2: El problema y su corrección, sobre el flood map. Los tres paneles muestran el mismo módulo y los mismos eventos. El **panel izquierdo** es la situación normal, con los 61 sensores operativos: la retícula de puntos brillantes aparece completa y regular. El **panel central** muestra qué ocurre al apagar el sensor Ich 30: dentro del círculo rojo la retícula se deforma y aparece un hueco, porque los eventos que ocurrían en esa zona se reconstruyen ahora en posiciones equivocadas. El **panel derecho** es el resultado tras reconstruir la carga del sensor con la red: **la retícula se recompone** y el hueco desaparece. La escala de color indica el número de cuentas en cada píxel, de azul oscuro (ninguna) a amarillo (máximo).

2.1. Cómo se mide, en cristiano

Todo el trabajo se apoya en una única cantidad: el **desplazamiento de la posición reconstruida**, que llamamos ΔR y medimos en milímetros. Para cada evento se calcula la posición con los 61 sensores (la verdad), después con el sensor apagado (el fallo), y por último con el sensor reconstruido por la red. La comparación entre la segunda y la tercera dice cuánto del daño se ha reparado.

De ahí sale la **recuperación**, expresada en tanto por ciento: si el fallo desplazaba la posición un milímetro y tras la reconstrucción se desplaza medio, la recuperación es del 50 %. El 100 % significaría reconstrucción perfecta y el 0 % que la red no aporta nada. Un valor *negativo* —que aparecerá más adelante— significa que la reconstrucción empeora la posición respecto a no hacer nada.

Se reportan dos versiones de esa cantidad, y merece la pena distinguirlas porque aparecen en todas las tablas. La **recuperación media** promedia sobre todos los eventos y es la cifra honesta, la que resume el comportamiento global. La **recuperación p90** se fija en el percentil 90 de la distribución, es decir, en el 10 % de eventos peores: describe el régimen desfavorable, que es el que estropea la imagen.

Cifra principal. Con un sensor averiado, la red recupera de media el **52.6 %** del desplazamiento de posición, y el **58.1 %** en el 10 % de eventos peores. El modelo tiene **38 305 parámetros**, un tamaño muy modesto.




Figura 3: Recuperación sensor a sensor. El experimento se repite apagando cada uno de los 61 sensores por separado. Cada hexágono representa un sensor en su posición real; el número grande es el porcentaje recuperado cuando *ese* sensor es el averiado, y el número pequeño de debajo es su identificador. La escala de color va de rojo (recuperación nula) a verde (recuperación total), pasando por amarillo en torno al 50 %. El **panel izquierdo** muestra la recuperación media y el **panel derecho** la del 10 % de eventos peores. La lectura importante es que **el color es homogéneo en casi todo el detector**: no hay zonas catastróficas. Destaca en naranja el sensor Ich 31, con un 39.4 % frente al 58 % típico; su caso se explica en la Sección ?? y resultó no ser un defecto del sensor.

Ese comportamiento homogéneo tiene, sin embargo, una estructura reconocible que conviene señalar, porque es la misma que aparecía en la Figura ??.




Figura 4: Cómo varía el rendimiento del centro al borde. En lugar de mirar los 61 sensores a la vez, se recorren dos trayectos: el **panel izquierdo** sigue una línea radial desde el sensor central hasta un vértice, y el **derecho** recorre uno de los lados del hexágono. En ambos, el eje horizontal es la posición a lo largo del trayecto en milímetros y el vertical el porcentaje recuperado. La **línea verde continua** es la recuperación media y la **línea azul discontinua** la del 10 % de eventos peores; cada punto lleva la etiqueta del sensor correspondiente. La lectura es que el rendimiento se mantiene estable en torno al 55–58 % en casi todo el recorrido y **cae en el último punto**, que en ambos casos es un sensor de vértice o esquina (Ich 27 e Ich 4). Es coherente con que esos sensores reciben menos luz y tienen menos vecinos de los que extraer información.

3. ¿De dónde viene el rendimiento? La geometría importa

Una pregunta razonable es si la red está usando realmente la disposición física de los sensores o si simplemente tiene parámetros suficientes para memorizar correlaciones. El experimento que lo resuelve es una **ablación**: se entrena exactamente la misma red, con el mismo número de parámetros y los mismos datos, pero **barajando las etiquetas del grafo de vecindad**. El modelo sigue creyendo que cada sensor tiene seis vecinos, pero esos vecinos ya no son los que están físicamente al lado.




Figura 5: La geometría es esencial. Ambos paneles son el mismo mapa de sensores de la figura anterior, con la recuperación del 10 % de eventos peores. A la **izquierda**, la red entrenada con la geometría real del detector: recuperación media del **58.0 %**, con los hexágonos en tonos verdes y amarillos. A la **derecha**, la misma red con el grafo de vecindad barajado: la recuperación cae al **28.1 %** y el mapa se vuelve azul y morado. La escala de color es idéntica en los dos paneles, de morado oscuro (20 %) a amarillo (70 %), de modo que la comparación es directa. **Perder la geometría cuesta treinta puntos**, prácticamente la mitad del rendimiento.

3.1. ¿Y hace falta una red neuronal?

La segunda pregunta obligada es si un método clásico bastaría. Se compararon tres procedimientos sobre exactamente los mismos eventos de prueba: promediar los vecinos inmediatos del sensor averiado, ajustar una regresión lineal que prediga su carga a partir de los otros sesenta, y la red. Todos ellos excluyen, por supuesto, el sensor que deben reconstruir.

Tabla 1: Comparación con métodos clásicos, sobre los mismos eventos.

Método	Recuperación p90 (%)	Error de carga (ADC)
Media de los vecinos	45.4	0.891
Regresión lineal (60 sensores)	46.6	0.831
Red neuronal	58.0	0.619
Ventaja de la red	+11,4 puntos	−25 %

La regresión lineal apenas mejora al promedio de vecinos, mientras que la red saca once puntos a ambas. La relación entre la carga de un sensor y la de sus vecinos es, por tanto, **claramente no lineal**, y ahí es donde el aprendizaje profundo aporta.

Un experimento complementario refuerza el diseño elegido: si en lugar de usar los sesenta sensores se ajusta la regresión usando solo los vecinos a uno, dos o tres pasos de distancia, el rendimiento **satura ya en el segundo anillo**. Añadir sensores más lejanos no aporta nada. Esto confirma que el problema es local y justifica una arquitectura que solo mira a los vecinos.

4. Los tres flancos físicos

Recuperar la posición no basta: hay que comprobar que la reconstrucción no estropea las otras magnitudes que el detector debe medir. Se examinaron tres.

4.1. Energía: el espectro se conserva

Sumando la carga de todos los sensores se obtiene la energía del evento, y su histograma debe reproducir el espectro de la fuente de ^{22}Na empleada. Si la reconstrucción sistemáticamente subestimara o sobreestimara, el espectro se desplazaría y la calibración en energía quedaría inservible.




Figura 6: Conservación del espectro de energía. El análisis se estratifica en tres zonas del detector según dónde ocurrió el evento: **verde** para el núcleo, **amarillo** para la corona intermedia y **rojo** para el borde. En el **panel izquierdo**, la altura de cada barra es el porcentaje del daño espectral que se repara, para cinco sensores averiados distintos; casi todas las barras superan el 80 %, con una media del 82.9 %. En el **panel derecho** se muestra el desplazamiento de la energía media en unidades ADC: las **barras claras y largas** son el desplazamiento que provoca el fallo sin corregir, y las **barras sólidas y cortas** el que queda tras la reconstrucción. La lectura es inmediata: **las barras sólidas son mucho más cortas que las claras**, es decir, la mayor parte del desplazamiento se elimina. El único caso flojo es el sensor Ich 13 evaluado sobre eventos de borde (barra roja del primer grupo, 52.8 %), que corresponde a reconstruir el sensor central cuando el evento ocurrió en una esquina.

4.2. Resolución espacial: la imagen se afila

El desplazamiento medio no lo dice todo. Un fallo no solo mueve la posición reconstruida: también la *emborrona*. Conviene por tanto separar las dos componentes, el sesgo (que la nube de puntos se desplace) y la dispersión (que se ensanche).




Figura 7: Descomposición del error en sesgo y emborronamiento. Los dos primeros paneles son histogramas bidimensionales del error de posición: cada punto representa la diferencia entre la posición reconstruida y la verdadera, en milímetros, de modo que el centro exacto significa error nulo y el color indica cuántos eventos caen en cada píxel, del negro (ninguno) al amarillo (máximo). El **panel izquierdo** corresponde al sensor averiado sin corregir y el **central** a la situación tras la reconstrucción: la nube es visiblemente **más compacta y está mejor centrada**. El **panel derecho** superpone los perfiles unidimensionales de ambas distribuciones: la **curva roja** es el caso degradado y la **curva azul** el reconstruido. La curva azul es **claramente más estrecha**, y su anchura a media altura pasa de 0.209 a 0,073 mm para este sensor. Agregando sobre los 61 sensores, la red elimina el **48.8 %** del emborronamiento y el **82.7 %** del sesgo.

4.3. Carga: cuánto se equivoca en la magnitud primaria

Por último, cabe preguntarse cuánto se equivoca la red al estimar la carga en sí, que es lo que realmente predice. Expresado en términos relativos, el error es de aproximadamente el **30 %** de la carga típica del sensor.




Figura 8: Error relativo de carga. En el **panel izquierdo**, cada punto rojo es uno de los 61 sensores, situado según su distancia al centro del detector; el eje vertical es el error relativo con que se reconstruye su carga. Se aprecia una **tendencia creciente clara**: los sensores del centro se reconstruyen con un error en torno al 25 % y los del borde superan el 35 %, lo que enlaza con el gradiente de iluminación de la Figura ?? . El **panel derecho** compara el error relativo medio de las distintas configuraciones ensayadas; las **barras verdes** son los dos *ensembles* y las **azules** el resto. Todas las variantes razonables se agrupan entre el 29 y el 33 %, salvo la última —un intento de que la red estimase su propia incertidumbre— que se dispara al 61.5 % y se descartó.

Una observación que merece destacarse. Un error del 30 % en la carga de un sensor se traduce en apenas 0,13 mm de error en la posición. La razón es que el centro de gravedad promedia sobre 61 sensores, de modo que un error grande en uno solo queda muy diluido. Esto explica por qué el método funciona bien en posición aunque la estimación de carga individual sea modesta, y es el argumento físico que justifica el enfoque.

5. Cuando falla más de un sensor

En los módulos reales los fallos no siempre son de un único sensor. A veces se estropea un grupo contiguo —por una sombra, una conexión en serie o un efecto térmico— y a veces aparecen varios sensores afectados a poca distancia unos de otros. Se estudiaron por tanto dos regímenes: **contiguo**, en el que los sensores averiados forman un grupo compacto, y **disperso**, en el que se reparten por el detector y que sirve de control.




Figura 9: Comportamiento frente al tamaño del fallo. En los dos primeros paneles el eje horizontal es el número de sensores averiados simultáneamente, de uno a ocho, y el vertical el error de posición que queda tras la reconstrucción en milímetros, de modo que **más abajo es mejor**. El **panel izquierdo** evalúa grupos contiguos, el caso físicamente realista, y el **central** sensores dispersos, como control. En ambos, la **línea negra de puntos** es la situación sin reconstruir, es decir, el daño que causa el fallo. La **línea gris** corresponde al modelo entrenado únicamente con un sensor apagado, y se ve cómo **se despega hacia arriba** a partir de cuatro o cinco sensores: fuera de aquello para lo que fue entrenado, se degrada deprisa. Las líneas **roja** (entrenada con grupos contiguos de uno a cuatro), **naranja** (dispersos) y **morada** (contiguos de uno a ocho) se mantienen **muy por debajo**, cerca de la mitad del error, incluso con ocho sensores caídos. El **panel derecho** cuantifica cuánto se gana entrenando con el tipo de fallo correcto: la **línea roja** indica la mejora del modelo entrenado en contiguo al evaluarse en fallos contiguos y la **azul** la del entrenado en disperso sobre fallos dispersos; ambas son positivas a partir de dos sensores, de modo que **conviene entrenar con el modo de fallo que se espera encontrar**.

La conclusión práctica es que **entrenar con varios sensores apagados sale esencialmente gratis**: con un solo fallo el modelo rinde igual que el especializado, y a cambio aguanta mucho mejor los fallos grandes, incluso los de tamaño superior a los vistos durante el entrenamiento.

6. Cuánto varía de un detector a otro

Este es el resultado metodológicamente más relevante de las últimas semanas y conviene detenerse en él, porque cambia cómo deben leerse todas las cifras anteriores.

Las métricas se calculan sobre cinco módulos reservados para prueba. Cinco es una muestra holgada en número de eventos —varios millones— pero pobre en número de *detectores*. La

pregunta natural es cuánto dependen los resultados de qué cinco módulos concretos tocaron.

Existe una forma barata de responderla. Por el modo en que se cargan los datos, el modelo de referencia solo llega a ver 40 de los 149 módulos de entrenamiento; los demás nunca los ha observado y son, a efectos prácticos, un conjunto de prueba adicional de gran tamaño.




Figura 10: Variabilidad entre detectores. Histograma del rendimiento del *mismo* modelo evaluado sobre 40 módulos que nunca vio durante el entrenamiento. Cada **barra azul** agrupa los módulos cuyo porcentaje de recuperación cae en ese intervalo, y su altura es cuántos módulos hay. La **línea roja vertical** marca la media, situada en el 52.1 %. Lo llamativo es **la anchura de la distribución**: hay módulos en los que la recuperación no llega al 30 % y otros en los que supera el 63 %, con una desviación típica de **7.9 puntos**. Es decir, el mismo modelo, aplicado a detectores distintos, da resultados muy distintos.

Para poner esa cifra en contexto: entrenando tres veces el mismo modelo con distinta semilla de inicialización, la dispersión de los resultados es de apenas **0.09 puntos**. La variabilidad debida a **qué detector** se mide es, por tanto, unas **ochenta veces mayor** que la debida a cómo se entrenó.

Qué cambia y qué no. Las comparaciones entre modelos siguen siendo válidas, porque todas se hacen sobre *los mismos* cinco módulos: el efecto del detector se cancela al comparar. Lo que no puede afirmarse es que el método recupere el 58 % en un detector cualquiera; esa extrapolación tiene una incertidumbre de $\pm 3,5$ puntos y una dispersión de $\pm 7,9$ entre unidades. Es la diferencia entre *precisión relativa*, que es excelente, y *exactitud absoluta*, que es mucho más incierta.

Este resultado explicó además un caso que llevaba semanas abierto. El sensor Ich 31 aparecía como el peor del detector en la Figura ??, con un 39 % frente al 58 % típico, y se sospechaba que era un fotosensor defectuoso. Resultó que dos de los cinco módulos de prueba tienen una respuesta muy alejada de la que el modelo había visto al entrenar. Al reentrenar cubriendo los 149 módulos, ese sensor **sube de 38.6 a 49.5 %**. No era un sensor malo: era un sensor que la red no sabía tratar porque nunca había visto detectores parecidos.

7. Detección automática de sensores averiados

Todo lo anterior presupone saber qué sensor está estropeado. En los módulos reales esa información no viene dada, así que se desarrolló un procedimiento para identificarlos. La dificultad está en la Figura ?? : un umbral único no sirve, porque un sensor de esquina sano se activa menos que un sensor central averiado. El criterio compara por tanto cada sensor **con lo que se espera de un sensor en su misma posición**, estimado sobre los módulos sanos.




Figura 11: Validación del detector de sensores averiados. Como en los módulos reales no hay diagnóstico de referencia, se degradaron artificialmente sensores de módulos sanos para tener una verdad conocida. El **panel izquierdo** muestra las curvas ROC: el eje horizontal es la fracción de sensores sanos marcados por error y el vertical la fracción de averiados correctamente detectados, de modo que **cuanto más pegada a la esquina superior izquierda, mejor**. Cada color corresponde a una severidad del fallo: la **curva azul** es un sensor completamente muerto, la **naranja** uno que perdió el 70 % de su señal, la **verde** el 50 % y la **roja** el 30 %. La curva azul llega prácticamente al vértice, con área bajo la curva igual a **1.000**: los sensores muertos se detectan sin ambigüedad. La degradación se va notando conforme el fallo es más sutil, hasta 0.868 para el caso del 30 %. El **panel derecho** comprueba que el criterio no penaliza a los sensores de borde: la **línea roja** corresponde a los sensores periféricos y la **azul** a los centrales, y ambas prácticamente se superponen, lo que confirma que la corrección por posición funciona.

Aplicado a los 62 módulos averiados reales, el procedimiento señala sensores defectuosos en 48 de ellos, marcando 278 canales en total. Conviene ser explícito sobre sus límites: el método identifica con fiabilidad los sensores completamente inactivos, pero no separa las degradaciones moderadas del comportamiento normal, ni detecta sensores con ganancia anómalamente *alta*. El etiquetado manual de los módulos, actualmente en curso, confirma además que la casuística real es más variada de lo que el modelo estadístico contempla: hay fallos de un solo sensor, grupos contiguos y también conjuntos de dos o tres sensores separados por una o dos posiciones.

8. El techo de rendimiento: nueve intentos de superarlo

La pregunta que ha ocupado la mayor parte del esfuerzo experimental es si ese 52 % de recuperación media puede mejorarse. La respuesta, tras una campaña sistemática, es que **no con los datos disponibles**. La Tabla ?? resume las estrategias ensayadas.

Tabla 2: Estrategias ensayadas para superar el rendimiento del modelo de referencia. La banda de incertidumbre entre entrenamientos idénticos es de $\pm 0,35$ puntos en recuperación media, de modo que solo diferencias mayores son interpretables.

Estrategia	Resultado
Aumentar el tamaño de la red	Sin mejora en media (6 y 10 veces más parámetros da lo mismo), aunque sí mejora el peor sensor
Términos físicos en la función de coste	El de posición resulta redundante; el de energía empeora claramente
Geometría métrica (distancias y direcciones)	Efecto nulo: el problema es isótropo
Atención global entre todos los sensores	Peor de forma reproducible: el problema es local
Arquitecturas del estado del arte (<i>transformer</i> , U-Net de grafo)	Mejores en validación pero iguales o peores en prueba
Convolución hexagonal direccional	Empate exacto
Normalizaciones alternativas	Sin mejora o peor
Cobertura completa de módulos	Sin efecto en la media; mejora la homogeneidad
Mezclar módulos dentro de cada lote	Sin efecto
Promediar varios modelos	Única mejora real: entre 1.7 y 2.5 puntos, a coste de triplicar el coste de inferencia

Que nueve estrategias independientes converjan al mismo valor es, en sí mismo, el resultado más sólido del trabajo. Y hay un argumento adicional que lo refuerza: promediar tres modelos entrenados por separado —que es la forma habitual de estimar cuánta parte del error se debe a la variabilidad del ajuste y cuánta es irreducible— solo reduce el error un 2 %. Es decir, **el 98 % del error restante no procede del modelo**, sino de que la información necesaria sencillamente no está presente en los sensores supervivientes.

Conclusión central. El aprendizaje profundo es necesario, porque supera en once puntos a los métodos clásicos y la relación es marcadamente no lineal. La geometría es necesaria, porque prescindir de ella cuesta treinta puntos. Pero una vez incorporadas ambas, **una red pequeña de 38 000 parámetros satura el problema**. El límite no está en la arquitectura: está en la física.

9. Estado actual y decisiones abiertas

El método funciona y está caracterizado en sus tres flancos físicos. Quedan tres cuestiones sobre las que conviene decidir.

La primera es **qué configuración adoptar como modelo de producción**, y la respuesta depende del modo de fallo que se espere. Si lo habitual son sensores aislados, la versión entrenada con cobertura completa es preferible porque responde de forma más homogénea: su peor sensor rinde un 47.8 % frente al 39.4 % de la referencia. Si se esperan grupos contiguos, conviene la versión entrenada en régimen múltiple. Ambas mejoras no se acumulan tan bien como cabría esperar, y ahí queda trabajo por hacer.

La segunda es la **calibración en energía**, que no se ha aplicado. Todas las conclusiones se sostienen sin ella porque el diseño de la evaluación es diferencial y los efectos de calibración se cancelan, pero no puede descartarse que un conjunto calibrado permitiera superar el límite observado.

La tercera es la **validación sobre módulos averiados reales**. Hasta ahora el detector

de sensores defectuosos se ha validado con fallos inyectados artificialmente, que garantizan una verdad conocida a costa de representar un modo de fallo idealizado. El etiquetado manual en curso proporcionará la referencia necesaria para medir el acuerdo con el procedimiento automático sobre datos reales.

Las figuras de este informe proceden de las evaluaciones documentadas en el repositorio del proyecto. Todas las comparaciones entre modelos se han realizado sobre los mismos módulos de prueba y con el mismo número de eventos.